

Raport 2

Eksploracja danych

Mikoaj Langner, Marcin Kostrzewa

nr albumów: 255716, 255749

2021-04-19

Spis treści

1	Wstp	1
2	Zadanie 1	1
3	Zadanie 2	6
3.1	Wczytanie i przygotowanie danych	6
4	Zadanie 3	9

1 Wstp

Sprawozdanie zawiera rozwizanie zada z listy 2. Dotyczy one zagadnie dyskretyzacji i redukcji wymiaru.

2 Zadanie 1

W pierwszym zadaniu mamy zbada


```
data(iris)
```


```
intervals <- c(min(iris$Petal.Length), 2, 5, max(iris$Petal.Length))
for (method in c("interval", "frequency", "cluster", "fixed")) {
  petal.length.discretized <- if (method != "fixed")
    discretize(iris$Petal.Length, method=method) else
    discretize(iris$Petal.Length, method=method, breaks=intervals)
  print(ggplot(iris, aes(Petal.Length)) +
    geom_histogram() +
    geom_vline(xintercept=attributes(petal.length.discretized)$"discretized:breaks"
```

```


    ggtitle(method))
print(ggplot(iris, aes(Species, Petal.Length)) +
  geom_quasirandom(aes(col=Species)) +
  scale_color_manual(values=wes_palette("GrandBudapest1", 3)) +
  geom_hline(yintercept=attributes(petal.length.discretized)$"discretized:breaks") +
  ggtitle(method))
discretized.table <- table(petal.length.discretized, iris$Species)
matchClasses(discretized.table)
}


```







Cases in matched pairs: 94.67 %







Cases in matched pairs: 95.33 %





Cases in matched pairs: 89.33 %





Cases in matched pairs: 94.67 %

3 Zadanie 2

3.1 Wczytanie i przygotowanie danych

Teraz naszym zadaniem jest ...

Wczytajmy dane i uzupełnijmy je o informacje geograficzne o wszystkich stanach.

```
data(state)
state <- as.data.frame(state.x77)
state_ <- state
state_$region <- state.region
state_$division <- state.division
```

By rozstrzygn, czy potrzebna jest normalizacja danych, przeanalizujemy wykresy pudekowe oraz wyznaczmy odchylenia standardowe i współczynniki zmienności.

```
plot_boxplot(data.frame(state, all="all"), by="all")
```

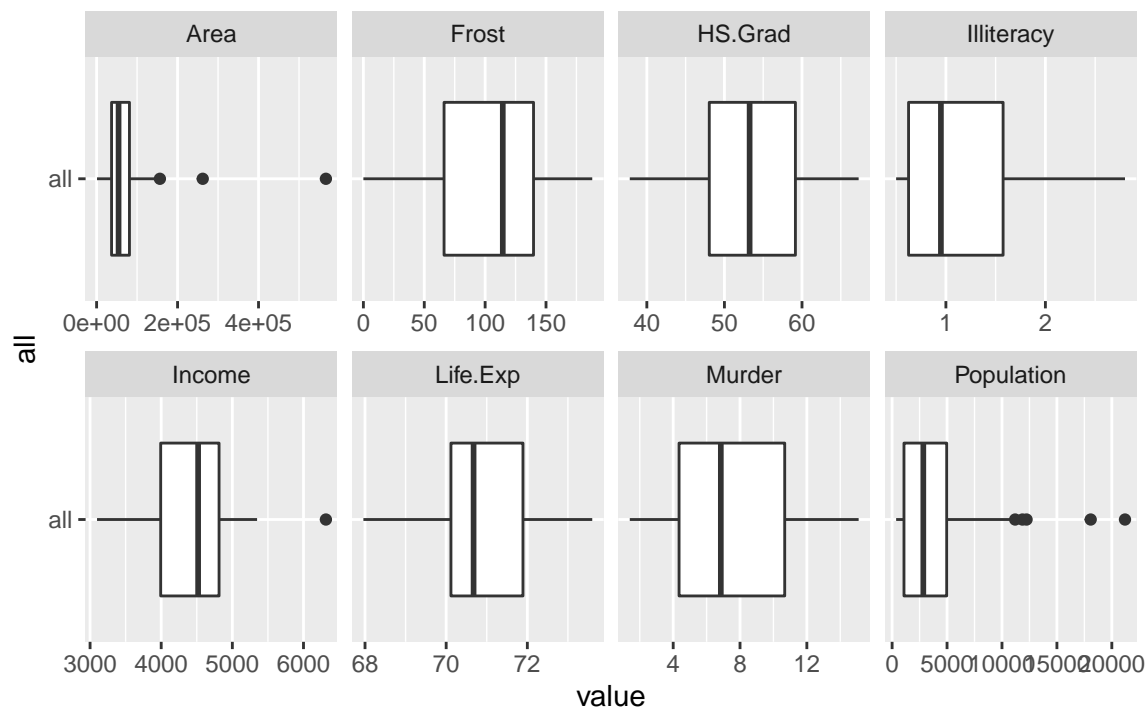



Tabela 1: Odchylenie standardowe i współczynnik zmienności dla zmiennych


	Population	Income	Illiteracy	Life Exp	Murder	HS Grad	Frost	Area
Odchylenie standardowe	4464.491433	614.4699392	0.6095331	1.3423936	3.6915397	8.0769978	51.9808481	85327.29962
Współczynnik zmienności	1.051354	0.1385252	0.5209685	0.0189393	0.5003442	0.1520863	0.4976149	1.20628

```
p <- plot_prcomp(state, prcomp_args=list(scale=TRUE, center=TRUE), variance_cap=0.8)[2]
print(p)
```



```
p <- plot_prcomp(state, prcomp_args=list(scale=TRUE, center=TRUE), variance_cap=1)[1]
```

```
print(p)
```



4 Zadanie 3