# Raport 3

Eksploracja danych

Mikołaj Langner, Marcin Kostrzewa
nr albumów: 255716, 255749

2021-04-19

## Spis treści



# 1 Wstęp

Raport zawiera rozwiązania listy 3.

W zadaniu pierwszym budujemy klasyfikator na bazie metody regresji liniowej i oceniamy jego skuteczność i dokładność.

W zadaniu drugim ....Porównamy ze sobą rezultaty zastosowania:

- metoda k-najblizszych sasiadów (*k-Nearest Neighbors*),
- drzewa klasyfikacyjne (*classification trees*),
- naiwny klasyfikator bayesowski (*naïve Bayes classifier*).

# 2 Zadanie 1

## 2.1 Wczytanie danych i podział na zbiór uczący i testowy

Wczytajmy dane o irysach i podzielmy je na zbiór uczący i testowy w proporcji $1:2$.

```
data(iris)
n <- dim(iris)[1]

train.set.index <- sample(1:n, 2/3*n)
train.set <- iris %>% slice(train.set.index) %>% arrange(Species)
test.set <- iris %>% slice(-train.set.index) %>% arrange(Species)
```

## 2.2 Konstrukcja klasyfikatora i wyznaczenie prognoz

Stworzymy teraz macierze eksperymentu i wskaźnikową zarówno dla zbioru uczącego, jak i testowego. W tym celu wykorzystamy funckję `dummyVars` z pakietu Caret.

```
dummies <- dummyVars(" ~ .", data=iris)

train.dummies <- predict(dummies, newdata = train.set)
train.X <- as.matrix(cbind(rep(1, nrow(train.dummies)),
                           train.dummies[, 1:4]))
train.Y <- train.dummies[, 5:7]

test.dummies <- predict(dummies, newdata = test.set)
test.X <- as.matrix(cbind(rep(1, nrow(test.dummies)), test.dummies[, 1:4]))
test.Y <- test.dummies[, 5:7]
```

Wykorzystując metodę najmniejszych kwadratów, wyznaczamy przewidywane prognozy klas dla obu zbiorów.

```
Y.hat <- solve(t(train.X) %*% train.X) %*% t(train.X) %*% train.Y

train.proba <- train.X %*% Y.hat
test.proba <- test.X %*% Y.hat
```

Przedstawmy prognozy klas na wykresach.

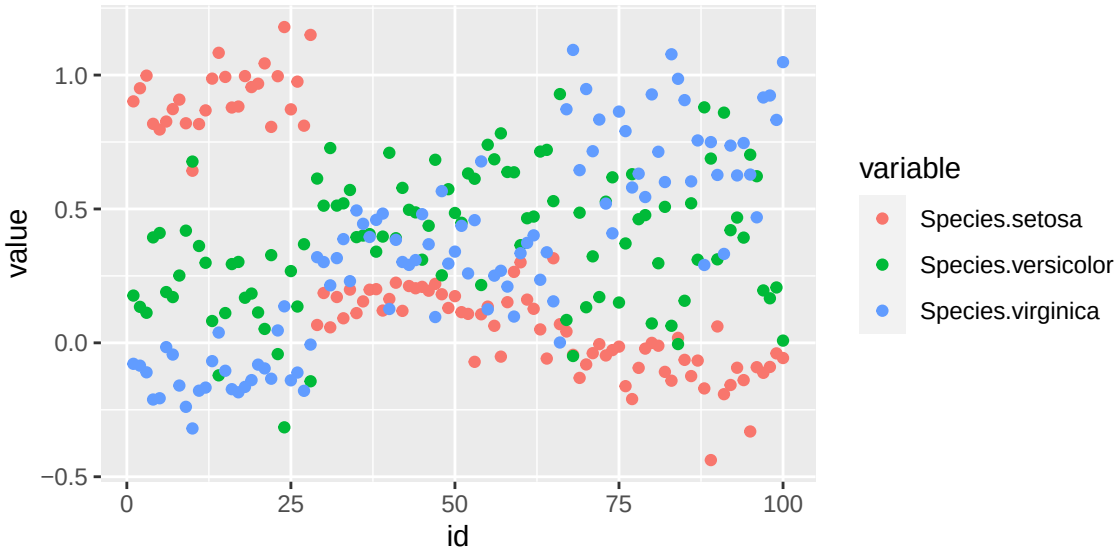


Rysunek 1: Prognozy klas dla zbioru uczacego.

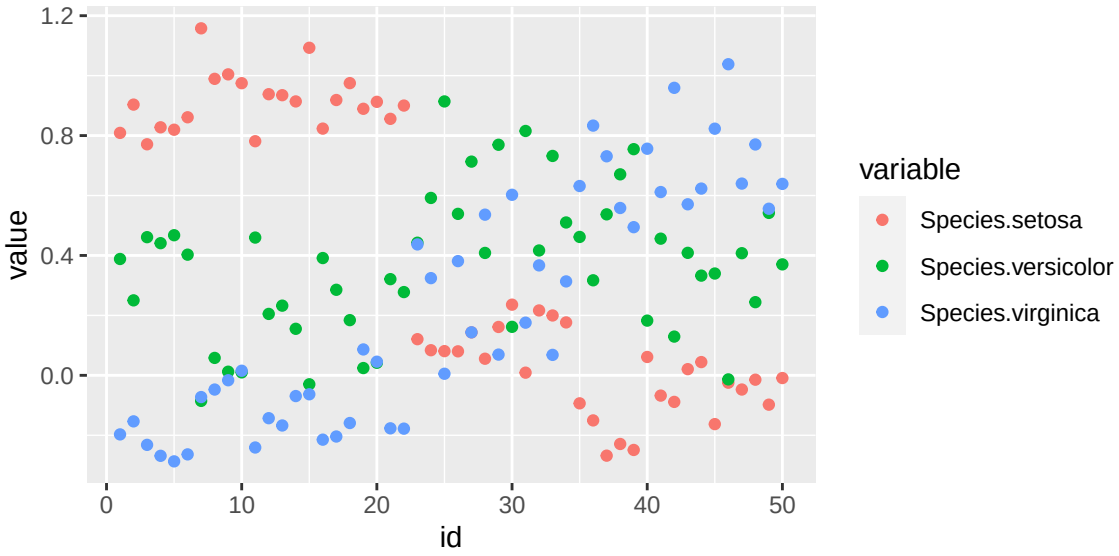


Rysunek 2: Prognozy klas dla zbioru testowego.

## 2.3 Ocena jakości klasyfikacji

Wyznaczmy teraz macierz pomyłek dla zbioru uczącego.

| | Species.setosa | Species.versicolor | Species.virginica |
|---|---|---|---|
| setosa | 27 | 1 | 0 |
| versicolor | 0 | 31 | 7 |
| virginica | 0 | 7 | 27 |

Tabela 1: Macierz pomylek dla zbioru uczacego.

Błąd klasyfikacji to 0.15.

| | Species.setosa | Species.versicolor | Species.virginica |
|---|---|---|---|
| setosa | 22 | 0 | 0 |
| versicolor | 0 | 10 | 2 |
| virginica | 0 | 2 | 14 |

Tabela 2: Macierz pomylek dla zbioru testowego.

Błąd klasyfikacji wynosi 0.08.

Wnioski i napomnienie o maskowaniu

## 2.4 Zastosowanie regresji liniowej do modelu o rozszerzonej ilości cech

Najpierw uzupełnijmy dane o irysach o składniki wielomianowe stopnia 2.

```
iris.quad <- (iris %>% select(-Species))^2
colnames(iris.quad) <- c("SL^2", "SW^2", "PL^2", "PW^2")
iris <- cbind(iris, combn(iris %>% select(-Species), 2,
                          FUN = Reduce, f = `*`),
              iris.quad)
```

Podobnie jak poprzednio podzielimy dane na zbiory: uczący i testowy, a następnie utworzymy macierze: eksperymentu i indykatorów.

```
train.set.index <- sample(1:n, 2/3*n)
train.set <- iris %>% slice(train.set.index) %>% arrange(Species)
test.set <- iris %>% slice(-train.set.index) %>% arrange(Species)

dummies <- dummyVars(" ~ .", data=iris)
train.dummies <- predict(dummies, newdata = train.set)
train.X <- as.matrix(cbind(rep(1, nrow(train.dummies)), train.dummies[, -c(5:7)]))
train.Y <- train.dummies[, 5:7]
```

```
test.dummies <- predict(dummies, newdata = test.set)
test.X <- as.matrix(cbind(rep(1, nrow(test.dummies)), test.dummies[, -c(5:7)]))
test.Y <- test.dummies[, 5:7]
```

Ponownie, wyznaczymy prognozy klas i zwizualizujemy to przypisanie na wykresach.

```
Y.hat <- solve(t(train.X) %*% train.X) %*% t(train.X) %*% train.Y

train.proba <- train.X %*% Y.hat
test.proba <- test.X %*% Y.hat
```

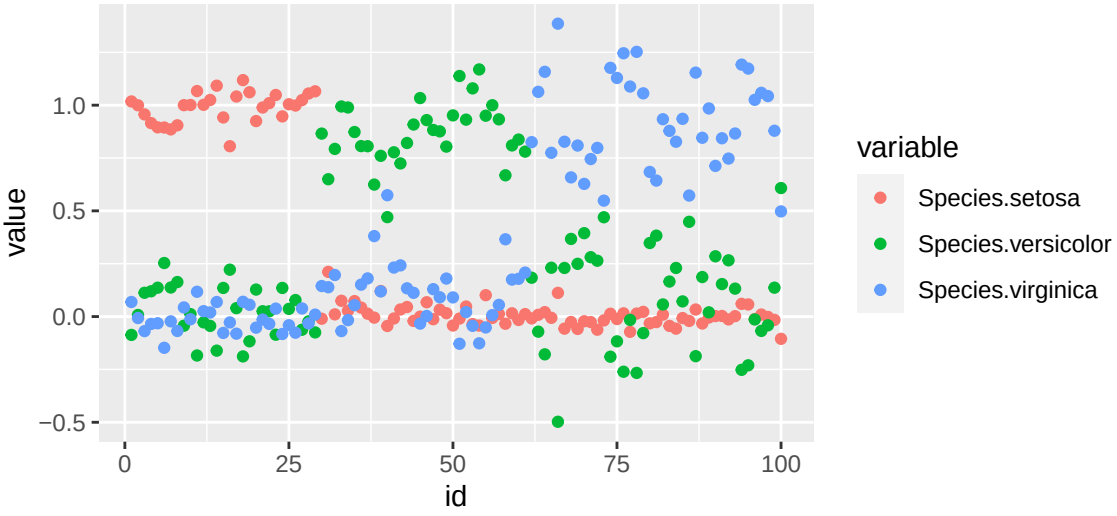


Rysunek 3: Prognozy klas dla zbioru uczacego o rozszerzonej liczbie cech.

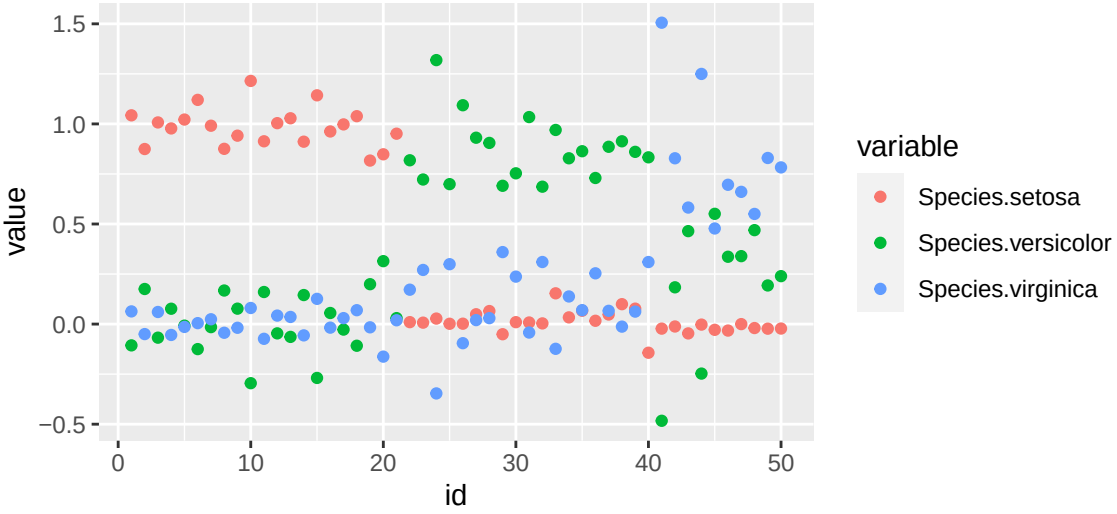


Rysunek 4: Prognozy klas dla zbioru uczacego o rozszerzonej liczbie cech.

Wyznaczymy także macierze pomyłek i błędy klasyfikacji.

| | Species.setosa | Species.versicolor | Species.virginica |
|---|---|---|---|
| setosa | 29 | 0 | 0 |
| versicolor | 0 | 31 | 1 |
| virginica | 0 | 1 | 38 |

Tabela 3: Macierz pomylek dla zbioru uczacego dla przypadku o rozszerzonej liczbie cech.

Błąd klasyfkacji wynosi 0.02.

| | Species.setosa | Species.versicolor | Species.virginica |
|---|---|---|---|
| setosa | 21 | 0 | 0 |
| versicolor | 0 | 18 | 0 |
| virginica | 0 | 2 | 9 |

Tabela 4: Macierz pomylek dla zbioru testowego dla przypadku o rozszerzonej liczbie cech.

Błąd klasyfikacji wynosi 0.04.

Wnioski i napomnienie o maskowaniu

# 3 Zadanie 2

## 3.1 Wczytanie i krótka anliza danych

Wczytajmy i przygotujmy dane do dalszych analizy.

```
library(MASS)
data(wine)
n <- dim(wine)[1]
wine <- drop_na(wine)
```

Przyjrzyjmy się naszym danym na wykresach pudełkowych.

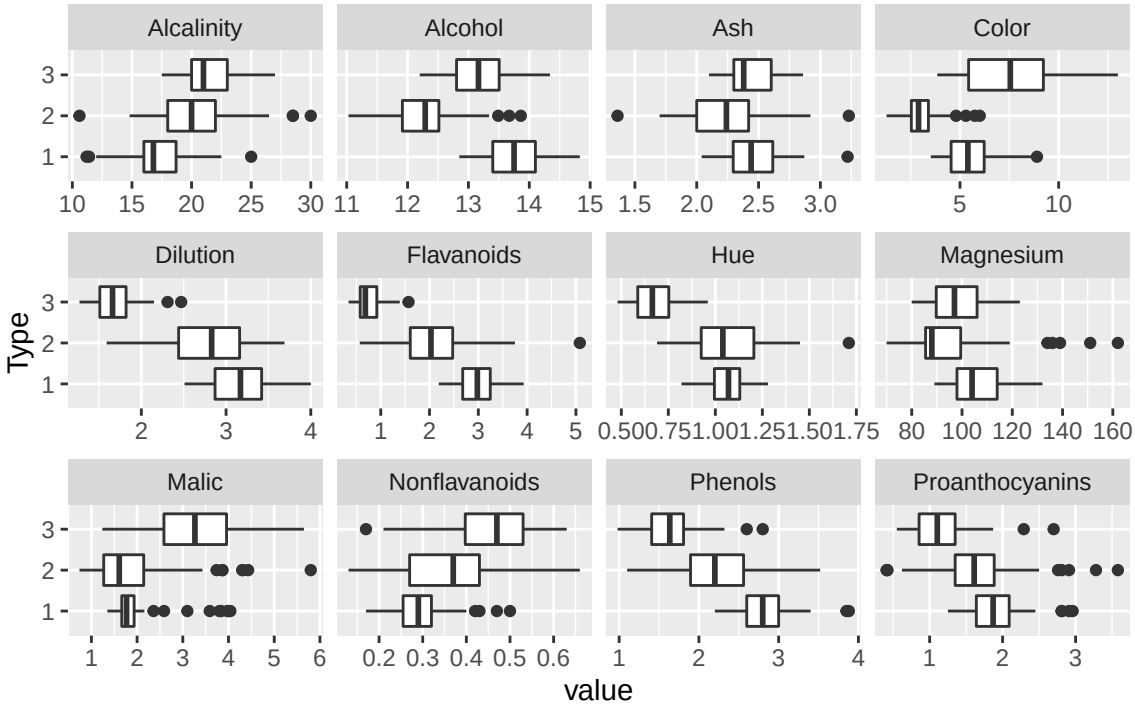

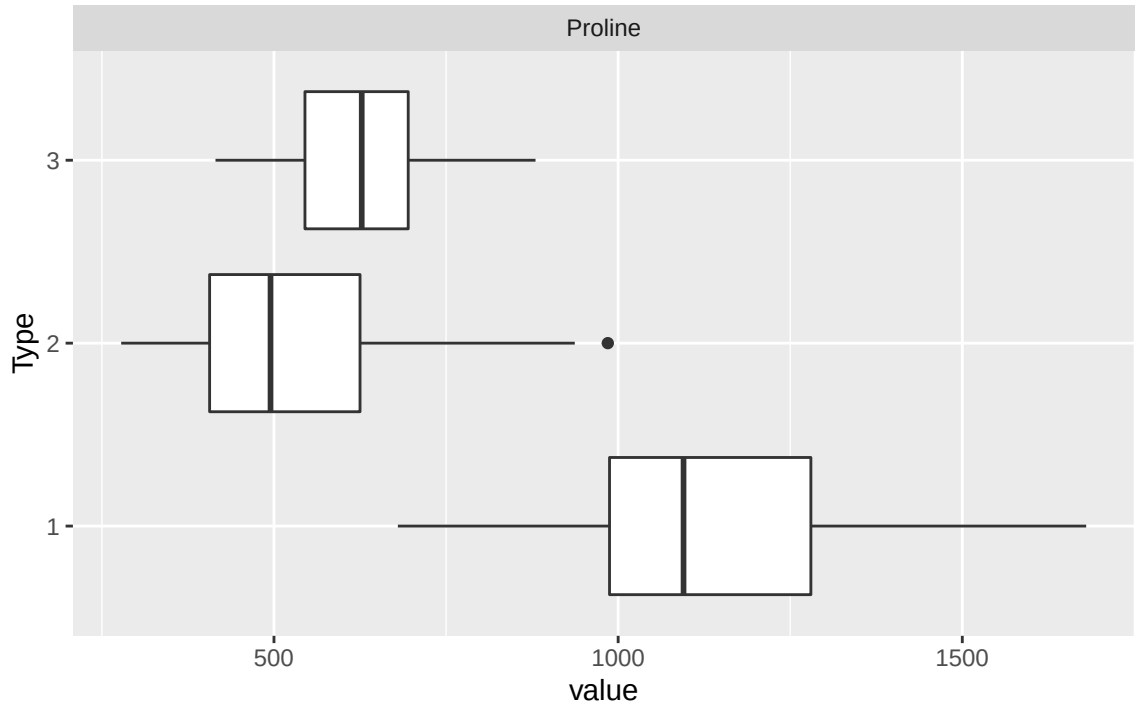


Możemy zauważyć, że zmiennymi, które dobrze odróżniają zmienne ...

Podzielmy nasze dane na zbiór uczący i testowy w stosunku 2 : 1.

```
set.seed(42)
train.index <- sample(n, 2/3 * n)
train.data <- wine %>% slice(train.index)
test.data <- wine %>% slice(-train.index)
train.subset <- data.frame(train.data[, c(1, 3, 6, 10)])
test.subset <- data.frame(test.data[, c(1, 3, 6, 10)])
```

```
train.etiquettes <- train.data$Type
test.etiquettes <- test.data$Type
subset.train.etiquettes <- train.subset$Type
subset.test.etiquettes <- test.subset$Type
```

```
cv <- trainControl(method="cv", number=5)
```

## 3.2 Metoda k-najbliższych sąsiadów

```
model.knn.basic <- ipredknn(Type ~ ., data = train.data, k=5)

basic.knn.test.pred <- predict(model.knn.basic, test.data, type="class")
basic.knn.train.pred <- predict(model.knn.basic, train.data, type="class")
```

| | 1 | 2 | 3 |
|---|---|---|---|
| 1 | 32 | 5 | 1 |
| 2 | 2 | 39 | 8 |
| 3 | 2 | 7 | 22 |

(a) Zbior uczacy

| | 1 | 2 | 3 |
|---|---|---|---|
| 1 | 21 | 1 | 2 |
| 2 | 0 | 15 | 9 |
| 3 | 2 | 4 | 6 |

(b) Zbior testowy

Tabela 5: Macierze pomylek dla metody KNN — wszystkie cechy.

Błędy klasyfikacji to 0.2118644 i 0.3.

```
knn.model.subset <- ipredknn(Type ~ ., data = train.subset, k=5)

subset.knn.test.pred <- predict(knn.model.subset, test.subset, type="class")
subset.knn.train.pred <- predict(knn.model.subset, train.subset, type="class")
```

| | 1 | 2 | 3 |
|---|---|---|---|
| 1 | 32 | 5 | 1 |
| 2 | 2 | 39 | 8 |
| 3 | 2 | 7 | 22 |

(a) Zbior uczacy

| | 1 | 2 | 3 |
|---|---|---|---|
| 1 | 21 | 1 | 2 |
| 2 | 0 | 15 | 9 |
| 3 | 2 | 4 | 6 |

(b) Zbior testowy

Tabela 6: Macierze pomylek dla metody KNN — wybrance cechy.

Błędy klasyfikacji to 0.2118644 i 0.3.

```
model <- train(Type ~ ., data = train.data, method = "knn", trControl = cv)

tuned.knn.test.pred <- predict(model, test.data)
tuned.knn.train.pred <- predict(model, train.data)
```

| | 1 | 2 | 3 |
|---|---|---|---|
| 1 | 35 | 5 | 3 |
| 2 | 1 | 32 | 11 |
| 3 | 0 | 14 | 17 |

(a) Zbior uczacy

| | 1 | 2 | 3 |
|---|---|---|---|
| 1 | 22 | 1 | 3 |
| 2 | 0 | 14 | 7 |
| 3 | 1 | 5 | 7 |

(b) Zbior testowy

Tabela 7: Macierze pomylek dla metody KNN — stuningowany model.

Błędy klasyfikacji to 0.2881356 i 0.2833333.

## 3.3 Drzewa klasyfikacyjne

```
basic.tree.model <- rpart(Type ~ ., data = train.data)

basic.tree.test.pred <- predict(basic.tree.model, newdata = test.data,
                                type = "class")
basic.tree.train.pred <- predict(basic.tree.model, newdata = train.data,
                                 type = "class")
```

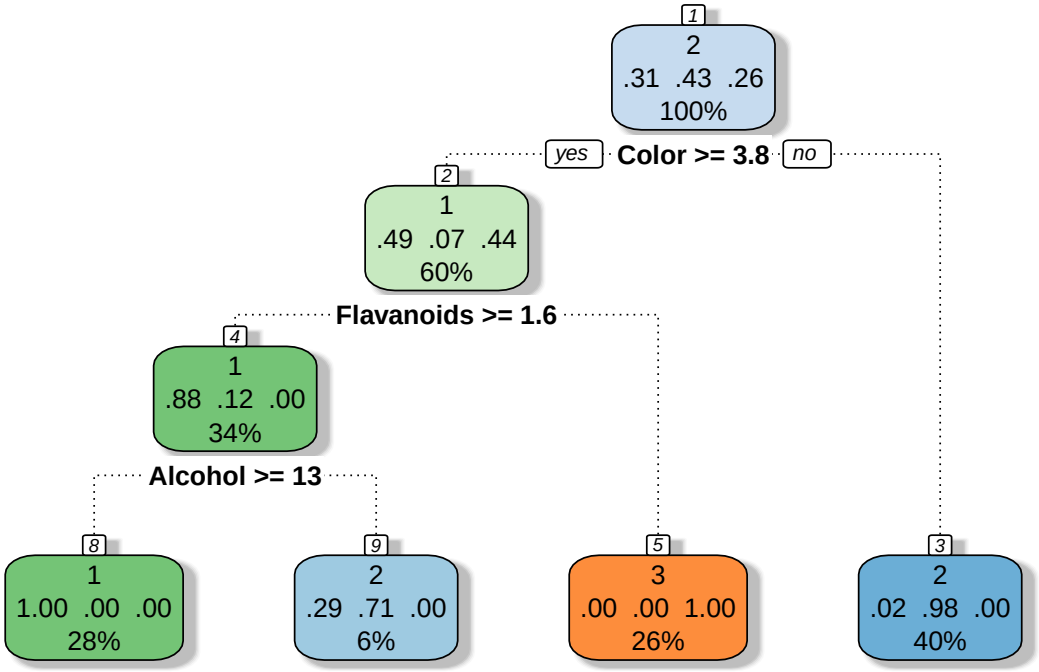


| | 1 | 2 | 3 |
|---|---|---|---|
| 1 | 33 | 0 | 0 |
| 2 | 3 | 51 | 0 |
| 3 | 0 | 0 | 31 |

(a) Zbior uczacy

| | 1 | 2 | 3 |
|---|---|---|---|
| 1 | 17 | 1 | 0 |
| 2 | 6 | 18 | 0 |
| 3 | 0 | 1 | 17 |

(b) Zbior testowy

Tabela 8: Macierze pomylek dla metody drzew klasyfikacyjnych — wszystkie cechy.

Błędy klasyfikacji to 0.0254237 i 0.1333333.

```
subset.tree.model <- rpart(Type ~ ., data = train.subset)

subset.tree.test.pred <- predict(subset.tree.model, newdata = test.subset,
                                 type = "class")
subset.tree.train.pred <- predict(subset.tree.model, newdata = train.subset,
                                  type = "class")
```

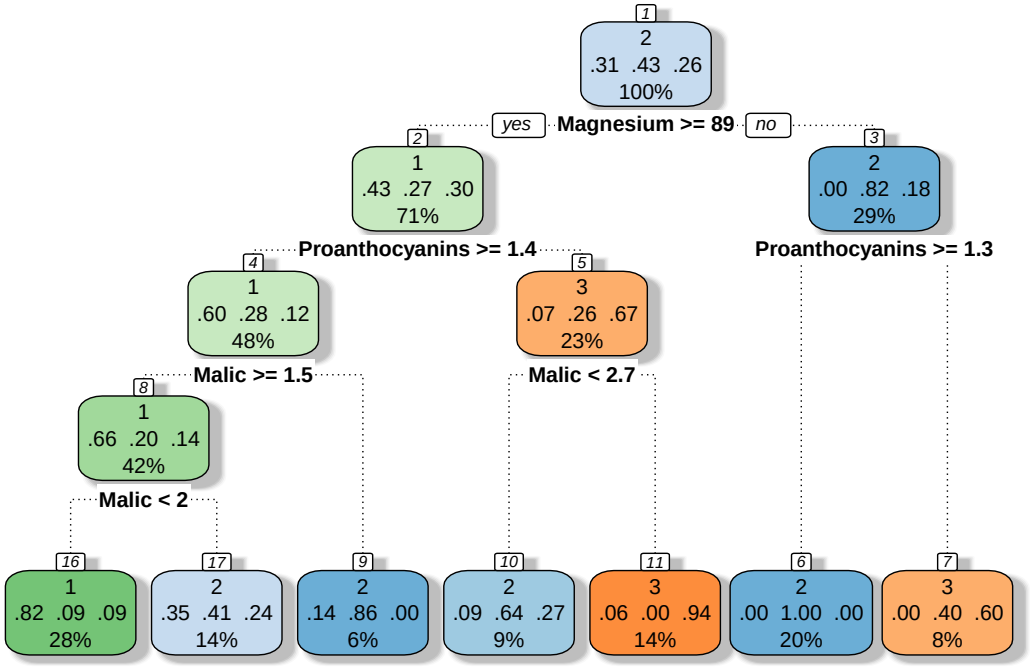


| | 1 | 2 | 3 |
|---|---|---|---|
| 1 | 27 | 3 | 3 |
| 2 | 8 | 44 | 7 |
| 3 | 1 | 4 | 21 |

(a) Zbior uczacy

| | 1 | 2 | 3 |
|---|---|---|---|
| 1 | 11 | 1 | 0 |
| 2 | 12 | 16 | 7 |
| 3 | 0 | 3 | 10 |

(b) Zbior testowy

Tabela 9: Macierze pomylek dla metody drzew klasyfikacyjnych — wybrane cechy.

Błędy klasyfikacji to 0.220339 i 0.3833333.

```
tuned.tree.model <- train(Type ~ ., data = train.data, method = "rpart",
                          trControl = cv)

tuned.tree.test.pred <- predict(tuned.tree.model, test.data)
tuned.tree.train.pred <- predict(tuned.tree.model, train.data)
```

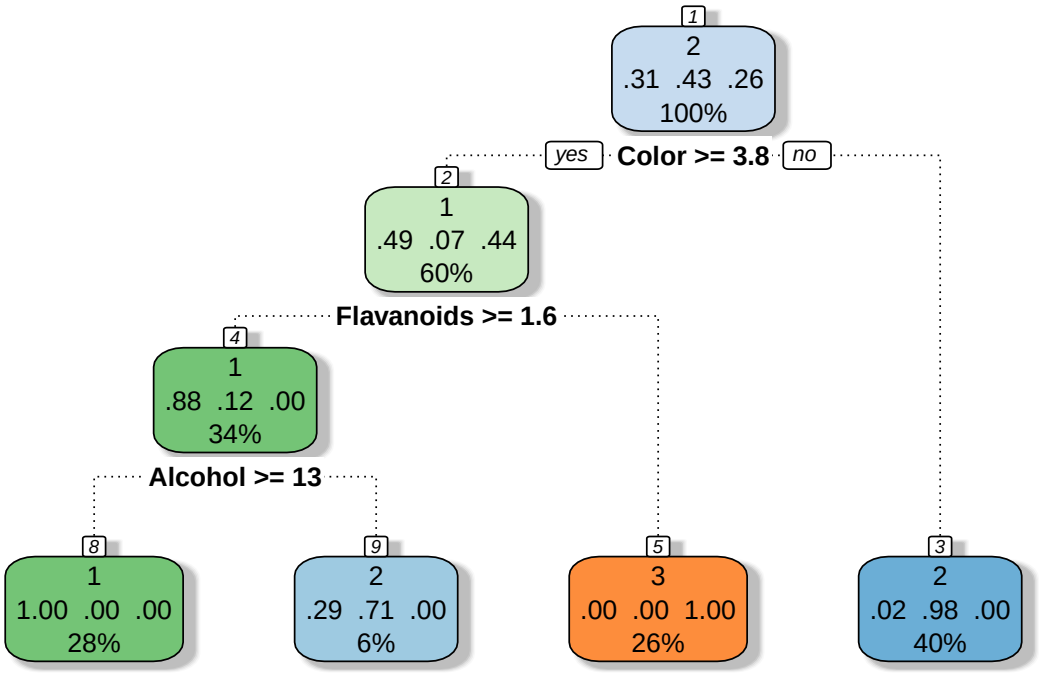


| | 1 | 2 | 3 |
|---|---|---|---|
| 1 | 33 | 0 | 0 |
| 2 | 3 | 51 | 0 |
| 3 | 0 | 0 | 31 |

(a) Zbior uczacy

| | 1 | 2 | 3 |
|---|---|---|---|
| 1 | 17 | 1 | 0 |
| 2 | 6 | 18 | 0 |
| 3 | 0 | 1 | 17 |

(b) Zbior testowy

Tabela 10: Macierze pomylek dla metody drzew klasyfikacyjnych — stuningowany model.

Błędy klasyfikacji to 0.0254237 i 0.1333333.

## 3.4 Naiwny klasyfikator bayesowski

```
bayes.model.basic <- naiveBayes(Type ~ ., data = train.data)

basic.bayes.train.pred <- predict(bayes.model.basic, train.data)
basic.bayes.test.pred <- predict(bayes.model.basic, test.data)
```

Błędy klasyfikacji to kolejno 0.0084746 i 0.0333333.

Powtórzmy teraz powyższe dla wybranego podzbioru naszych danych.

```
bayes.model.subset <- naiveBayes(Type ~ ., data = train.subset)
```

| | 1 | 2 | 3 |
|---|---|---|---|
| 1 | 36 | 0 | 0 |
| 2 | 0 | 50 | 1 |
| 3 | 0 | 0 | 31 |

(a) Zbior uczacy

| | 1 | 2 | 3 |
|---|---|---|---|
| 1 | 22 | 1 | 0 |
| 2 | 0 | 19 | 1 |
| 3 | 0 | 0 | 17 |

(b) Zbior testowy

Tabela 11: Macierze pomylek dla klasyfikatora bayesowskiego — wszystkie cechy.

```
basic.bayes.train.pred <- predict(bayes.model.subset, train.subset)
basic.bayes.test.pred <- predict(bayes.model.subset, test.subset)
```

| | 1 | 2 | 3 |
|---|---|---|---|
| 1 | 26 | 8 | 2 |
| 2 | 4 | 42 | 5 |
| 3 | 3 | 5 | 23 |

(a) Zbior uczacy

| | 1 | 2 | 3 |
|---|---|---|---|
| 1 | 13 | 8 | 2 |
| 2 | 2 | 13 | 5 |
| 3 | 1 | 0 | 16 |

(b) Zbior testowy

Tabela 12: Macierze pomylek dla klasyfikatora bayesowskiego — wybrane cechy.

Błędy klasyfikacji to kolejno 0.2288136 i 0.3.

Model “stunigowany”

```
model <- train(Type ~ ., data = train.data, method = "naive_bayes",
               trControl = cv)
```

| | 1 | 2 | 3 |
|---|---|---|---|
| 1 | 36 | 0 | 0 |
| 2 | 0 | 50 | 1 |
| 3 | 0 | 0 | 31 |

(a) Zbior uczacy

| | 1 | 2 | 3 |
|---|---|---|---|
| 1 | 22 | 1 | 0 |
| 2 | 0 | 19 | 1 |
| 3 | 0 | 0 | 17 |

(b) Zbior testowy

Tabela 13: Macierze pomylek dla klasyfikatora bayesowskiego — model stuningowany.

Błędy klasyfikacji w tym przypadku to kolejno 0.0084746 i 0.0333333.

```
# my.predict  <- function(model, newdata)
# { predict(model, newdata=newdata) }
#
#
# cv <- trainControl(method="cv", number=5)
#
#
# my.naiveBayes <- function(formula, data)
```

```
# { train(formula, data = data, method = "naive_bayes", trControl = cv)}
#
#
# my.tree <- function(formula, data)
# { }
#
#
# my.knn <- function(formula, data)
# { }
#
#
# blad.cv <- errorest(Class~., BreastCancer, model=my.naiveBayes, predict=my.predict,
#              estimator="cv", est.para=control.errorest(k = 5))
```