Raport 3

Eksploracja danych

Mikołaj Langner, Marcin Kostrzewa
nr albumów: 255716, 255749

2021-04-19

Spis treści

1 Wstęp **1**

2 Zadanie 1 **2**
2.1 Wczytanie danych i podział na zbiór uczący i testowy 2
2.2 Konstrukcja klasyfikatora i wyznaczenie prognoz 2
2.3 Ocena jakości klasyfikacji 4
2.4 Zastosowanie regresji liniowej do modelu o rozszerzonej ilości cech 4

3 Zadanie 2 **7**
3.1 Wczytanie i krótka anliza danych 7
3.2 Metoda k-najbliższych sąsiadów 8
3.3 Drzewa klasyfikacyjne 11
3.4 Naiwny klasyfikator bayesowski 14

1 Wstęp

Raport zawiera rozwiązania listy 3.

W zadaniu pierwszym budujemy klasyfikator na bazie metody regresji liniowej i oceniamy jego skuteczność i dokładność.

W zadaniu drugim ....Porównamy ze sobą rezultaty zastosowania:

- metoda k-najblizszych sasiadów (*k-Nearest Neighbors*),
- drzewa klasyfikacyjne (*classification trees*),
- naiwny klasyfikator bayesowski (*naïve Bayes classifier*).

2 Zadanie 1

2.1 Wczytanie danych i podział na zbiór uczący i testowy

Wczytajmy dane o irysach i podzielmy je na zbiór uczący i testowy w proporcji $1:2$.

```
data(iris)
n <- dim(iris)[1]

train.set.index <- sample(1:n, 2/3*n)
train.set <- iris %>% slice(train.set.index) %>% arrange(Species)
test.set <- iris %>% slice(-train.set.index) %>% arrange(Species)
```

2.2 Konstrukcja klasyfikatora i wyznaczenie prognoz

Stworzymy teraz macierze eksperymentu i wskaźnikową zarówno dla zbioru uczącego, jak i testowego. W tym celu wykorzystamy funckję `dummyVars` z pakietu Caret.

```
dummies <- dummyVars(" ~ .", data=iris)

train.dummies <- predict(dummies, newdata = train.set)
train.X <- as.matrix(cbind(rep(1, nrow(train.dummies)),
                           train.dummies[, 1:4]))
train.Y <- train.dummies[, 5:7]

test.dummies <- predict(dummies, newdata = test.set)
test.X <- as.matrix(cbind(rep(1, nrow(test.dummies)), test.dummies[, 1:4]))
test.Y <- test.dummies[, 5:7]
```

Wykorzystując metodę najmniejszych kwadratów, wyznaczamy przewidywane prognozy klas dla obu zbiorów.

```
Y.hat <- solve(t(train.X) %*% train.X) %*% t(train.X) %*% train.Y

train.proba <- train.X %*% Y.hat
test.proba <- test.X %*% Y.hat
```

Przedstawmy prognozy klas na wykresach.

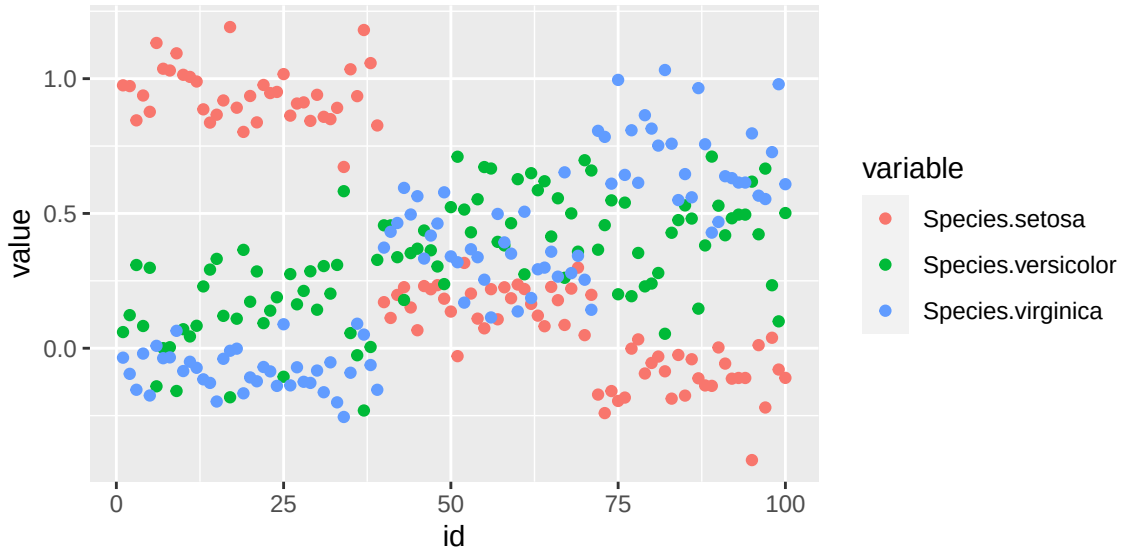

Rysunek 1: Prognozy klas dla zbioru uczacego.

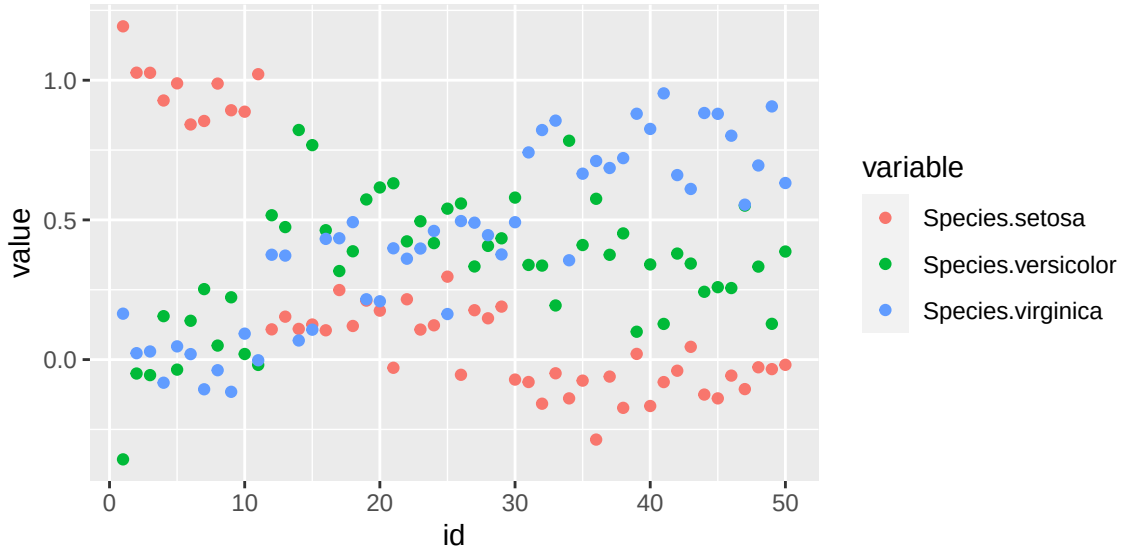

Rysunek 2: Prognozy klas dla zbioru testowego.

2.3 Ocena jakości klasyfikacji

Wyznaczmy teraz macierz pomyłek dla zbioru uczącego.

	Species.setosa	Species.versicolor	Species.virginica
setosa	39	0	0
versicolor	0	21	11
virginica	0	3	26

Tabela 1: Macierz pomylek dla zbioru uczacego.

Błąd klasyfikacji to 0.14.

	Species.setosa	Species.versicolor	Species.virginica
setosa	11	0	0
versicolor	0	13	5
virginica	0	2	19

Tabela 2: Macierz pomylek dla zbioru testowego.

Błąd klasyfikacji wynosi 0.14.

Wnioski i napomnienie o maskowaniu

2.4 Zastosowanie regresji liniowej do modelu o rozszerzonej ilości cech

Najpierw uzupełnijmy dane o irysach o składniki wielomianowe stopnia 2.

```
iris.quad <- (iris %>% select(-Species))^2
colnames(iris.quad) <- c("SL^2", "SW^2", "PL^2", "PW^2")
iris <- cbind(iris, combn(iris %>% select(-Species), 2,
                          FUN = Reduce, f = `*`),
              iris.quad)
```

Podobnie jak poprzednio podzielimy dane na zbiory: uczący i testowy, a następnie utworzymy macierze: eksperymentu i indykatorów.

```
train.set.index <- sample(1:n, 2/3*n)
train.set <- iris %>% slice(train.set.index) %>% arrange(Species)
test.set <- iris %>% slice(-train.set.index) %>% arrange(Species)

dummies <- dummyVars(" ~ .", data=iris)
train.dummies <- predict(dummies, newdata = train.set)
train.X <- as.matrix(cbind(rep(1, nrow(train.dummies)), train.dummies[, -c(5:7)]))
train.Y <- train.dummies[, 5:7]
```

```
test.dummies <- predict(dummies, newdata = test.set)
test.X <- as.matrix(cbind(rep(1, nrow(test.dummies)), test.dummies[, -c(5:7)]))
test.Y <- test.dummies[, 5:7]
```

Ponownie, wyznaczymy prognozy klas i zwizualizujemy to przypisanie na wykresach.

```
Y.hat <- solve(t(train.X) %*% train.X) %*% t(train.X) %*% train.Y

train.proba <- train.X %*% Y.hat
test.proba <- test.X %*% Y.hat
```

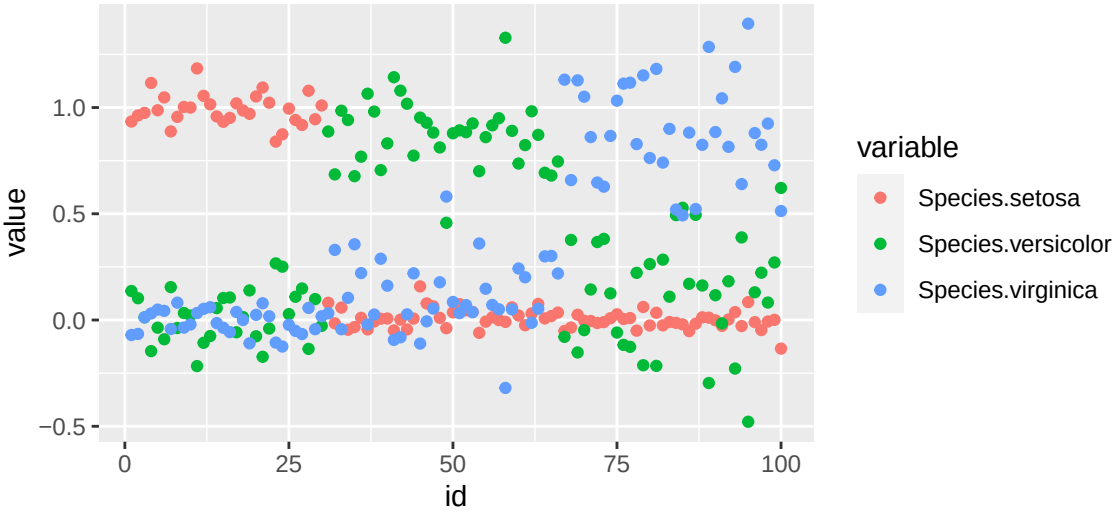

Rysunek 3: Prognozy klas dla zbioru uczacego o rozszerzonej liczbie cech.

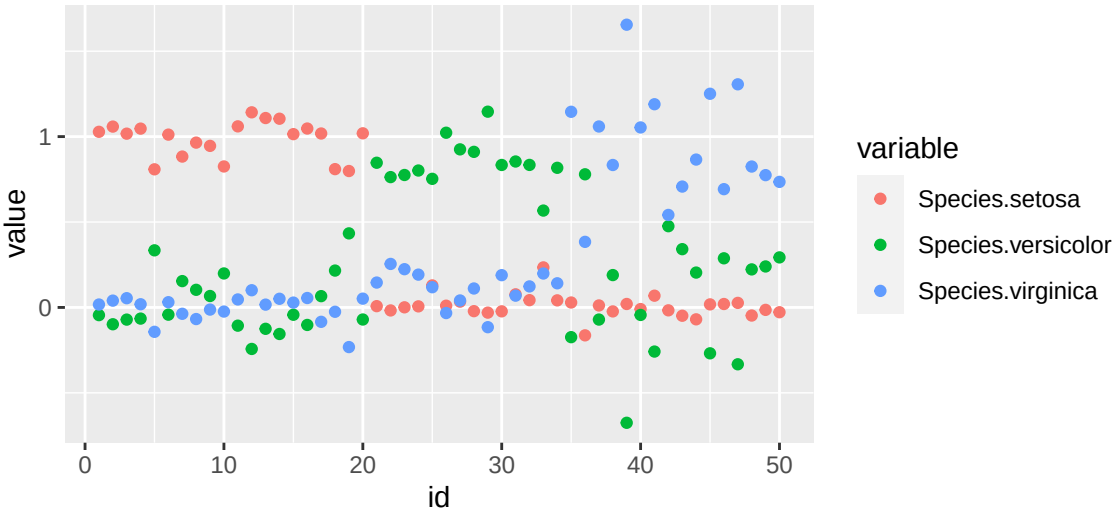

Rysunek 4: Prognozy klas dla zbioru uczacego o rozszerzonej liczbie cech.

Wyznaczymy także macierze pomyłek i błędy klasyfikacji.

	Species.setosa	Species.versicolor	Species.virginica
setosa	30	0	0
versicolor	0	35	1
virginica	0	2	32

Tabela 3: Macierz pomylek dla zbioru uczacego dla przypadku o rozszerzonej liczbie cech.

Błąd klasyfkacji wynosi 0.03.

	Species.setosa	Species.versicolor	Species.virginica
setosa	20	0	0
versicolor	0	14	0
virginica	0	1	15

Tabela 4: Macierz pomylek dla zbioru testowego dla przypadku o rozszerzonej liczbie cech.

Błąd klasyfikacji wynosi 0.02.

Wnioski i napomnienie o maskowaniu

3 Zadanie 2

3.1 Wczytanie i krótka anliza danych

Wczytajmy i przygotujmy dane do dalszych analizy.

```
data(wine)
n <- dim(wine)[1]
wine <- drop_na(wine)
```

Przyjrzyjmy się naszym danym na wykresach pudełkowych.

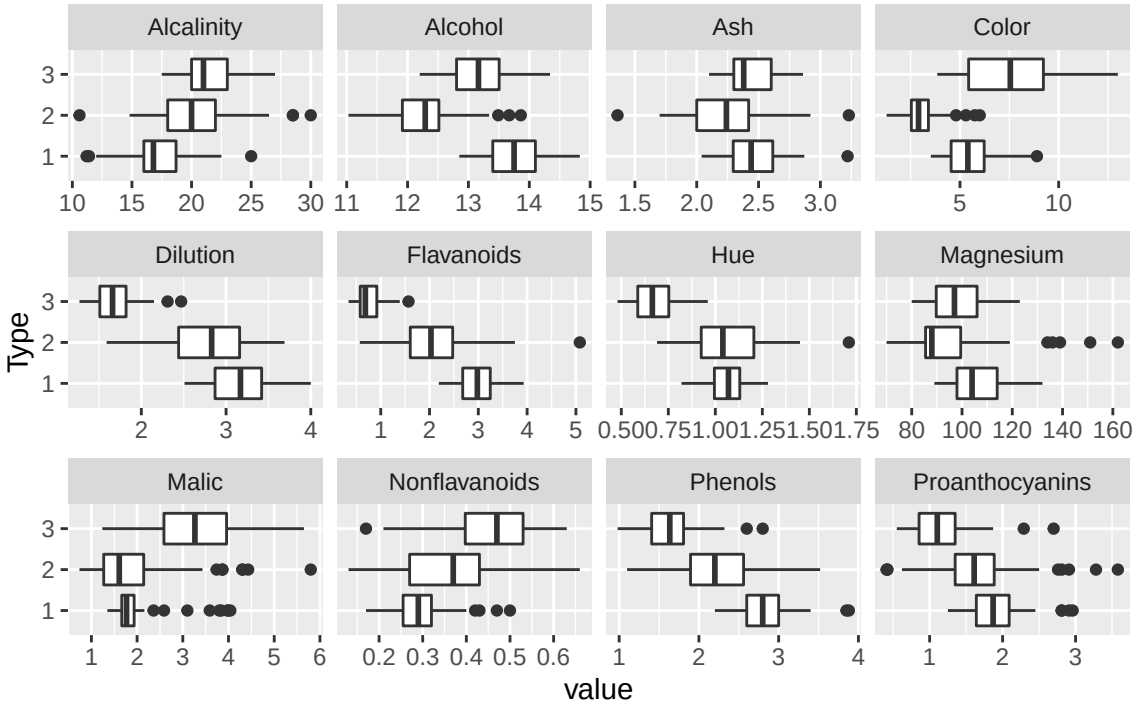

Page 1

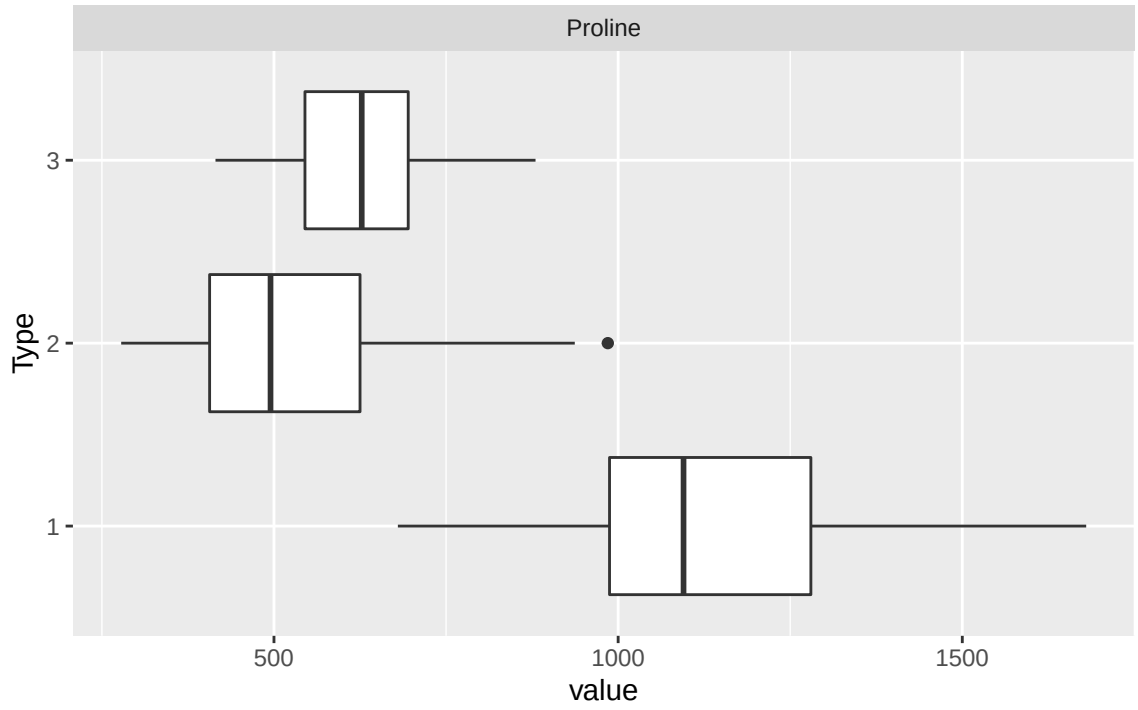

Możemy zauważyć, że zmiennymi, które dobrze odróżniają zmienne ...

Podzielmy nasze dane na zbiór uczący i testowy w stosunku 2 : 1.

```
set.seed(42)
train.index <- sample(n, 2/3 * n)
train.data <- wine %>% slice(train.index)
test.data <- wine %>% slice(-train.index)
train.subset <- data.frame(train.data[, c(1, 2, 7, 8)])
test.subset <- data.frame(test.data[, c(1, 2, 7, 8)])
```

```
train.etiquettes <- train.data$Type
test.etiquettes <- test.data$Type
subset.train.etiquettes <- train.subset$Type
subset.test.etiquettes <- test.subset$Type
```

```
cv <- trainControl(method="cv", number=5)
```

3.2 Metoda k-najbliższych sąsiadów

```
model.knn.basic <- ipredknn(Type ~ ., data = train.data, k=5)

basic.knn.test.pred <- predict(model.knn.basic, test.data, type="class")
basic.knn.train.pred <- predict(model.knn.basic, train.data, type="class")
```

	1	2	3
1	32	5	1
2	2	39	8
3	2	7	22

(a) Zbior uczacy

	1	2	3
1	21	1	2
2	0	15	9
3	2	4	6

(b) Zbior testowy

Tabela 5: Macierze pomylek dla metody KNN — wszystkie cechy.

Błędy klasyfikacji to 0.2118644 i 0.3.

```
knn.model.subset <- ipredknn(Type ~ ., data = train.subset, k=5)

subset.knn.test.pred <- predict(knn.model.subset, test.subset, type="class")
subset.knn.train.pred <- predict(knn.model.subset, train.subset, type="class")
```

	1	2	3
1	35	3	0
2	1	46	0
3	0	2	31

(a) Zbior uczacy

	1	2	3
1	22	2	0
2	1	16	0
3	0	2	17

(b) Zbior testowy

Tabela 6: Macierze pomylek dla metody KNN — wybrance cechy.

Błędy klasyfikacji to 0.0508475 i 0.0833333.

Zobaczmy jak zmienia się błąd klasyfikacji w zależności od parametru k.

Widzimy, że najlepsze rezultaty otrzymujemy dla $k = 9$. Potwierdza to ...

```
model <- train(Type ~ ., data = train.subset, method = "knn", trControl = cv)

tuned.knn.test.pred <- predict(model, test.data)
tuned.knn.train.pred <- predict(model, train.data)
```

	1	2	3
1	35	2	0
2	1	47	0
3	0	2	31

(a) Zbior uczacy

	1	2	3
1	23	2	0
2	0	18	2
3	0	0	15

(b) Zbior testowy

Tabela 7: Macierze pomylek dla metody KNN — stuningowany model.

Błędy klasyfikacji to 0.0423729 i 0.0666667.

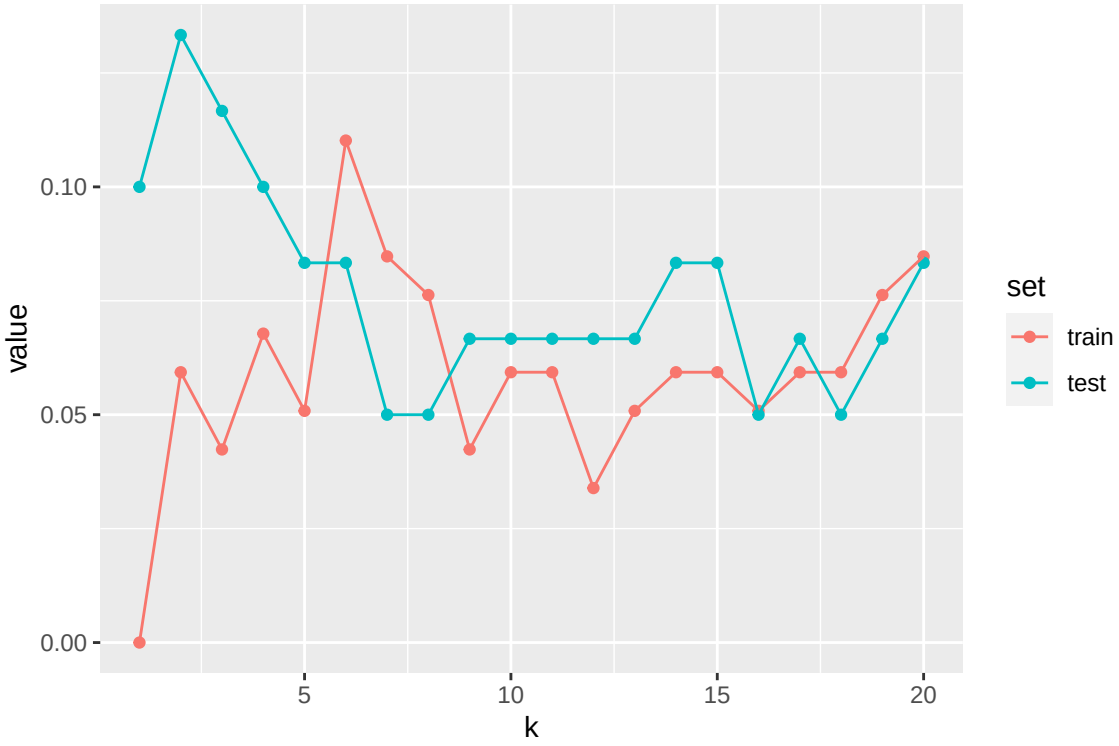

Rysunek 5: Blad klasyfikacji w zaleznosci od parametru k.

```
predictor  <- function(model, newdata)
{ predict(model, newdata=newdata) }

knn.predictor <- function(formula, data)
{ train(formula, data = data, method = "knn", trControl = cv)}

knn.error.cv <- errorest(Type~., wine[, c(1, 2, 7, 8)], model=knn.predictor, predict=pre
            estimator="cv", est.para=control.errorest(k = 5))
knn.error.cv
```

```
##
## Call:
## errorest.data.frame(formula = Type ~ ., data = wine[, c(1, 2,
##     7, 8)], model = knn.predictor, predict = predictor, estimator = "cv",
##     est.para = control.errorest(k = 5))
##
##   5-fold cross-validation estimator of misclassification error
##
## Misclassification error:  0.0843
```

3.3 Drzewa klasyfikacyjne

```
basic.tree.model <- rpart(Type ~ ., data = train.data)

basic.tree.test.pred <- predict(basic.tree.model, newdata = test.data,
                                type = "class")
basic.tree.train.pred <- predict(basic.tree.model, newdata = train.data,
                                 type = "class")
```

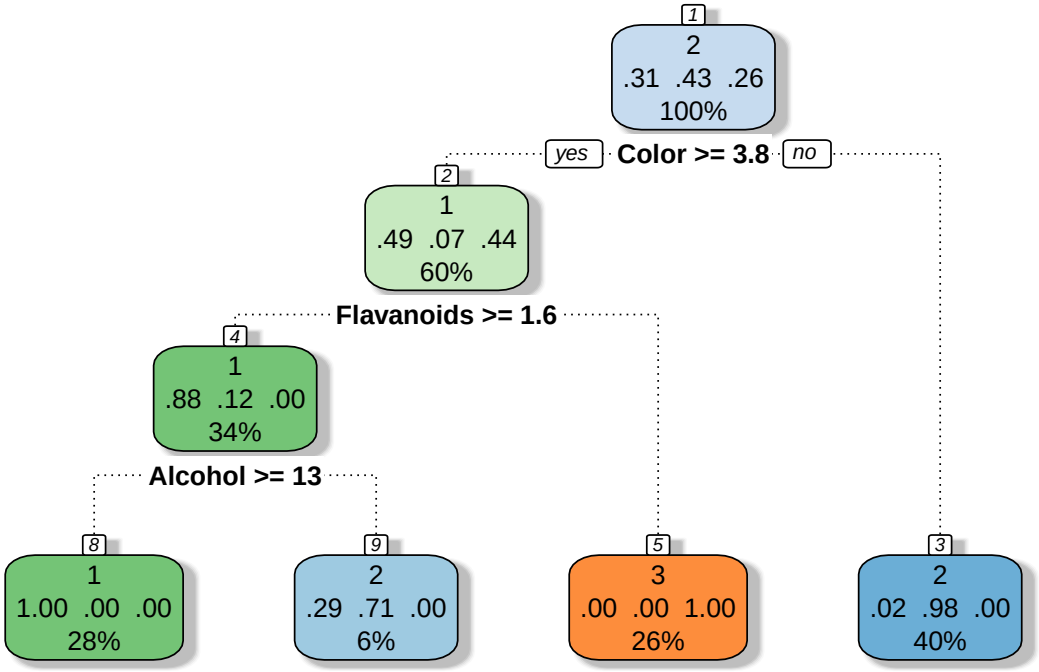

	1	2	3
1	33	0	0
2	3	51	0
3	0	0	31

(a) Zbior uczacy

	1	2	3
1	17	1	0
2	6	18	0
3	0	1	17

(b) Zbior testowy

Tabela 8: Macierze pomylek dla metody drzew klasyfikacyjnych — wszystkie cechy.

Błędy klasyfikacji to 0.0254237 i 0.1333333.

```
subset.tree.model <- rpart(Type ~ ., data = train.subset)

subset.tree.test.pred <- predict(subset.tree.model, newdata = test.subset,
                                 type = "class")
subset.tree.train.pred <- predict(subset.tree.model, newdata = train.subset,
```

```
                                    type = "class")
```

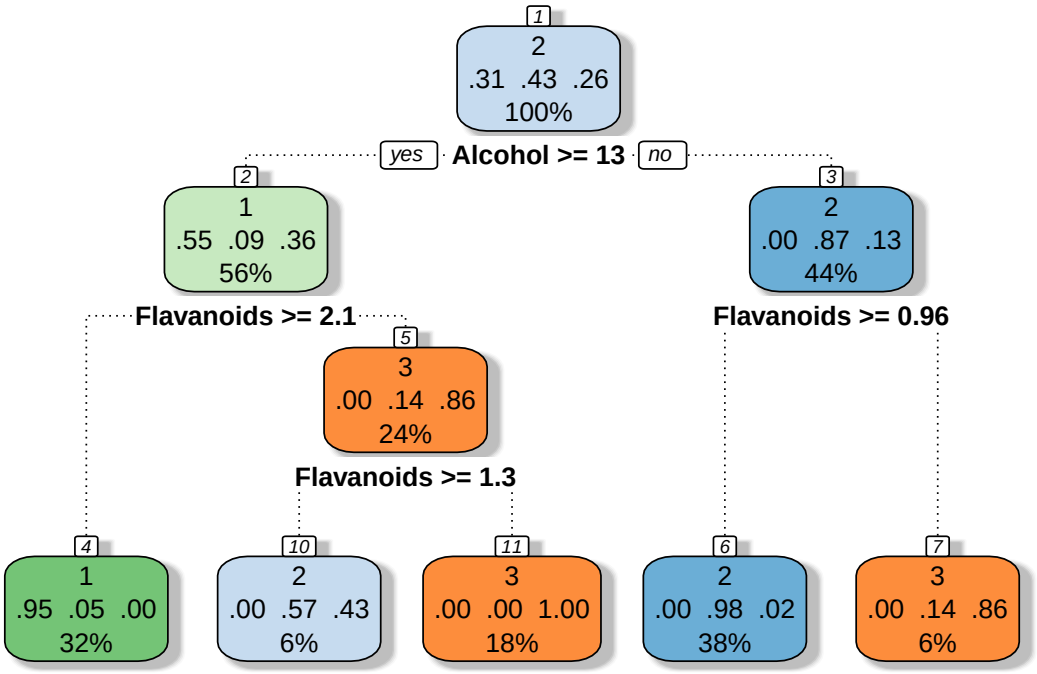

	1	2	3
1	36	2	0
2	0	48	4
3	0	1	27

(a) Zbior uczacy

	1	2	3
1	23	2	0
2	0	17	1
3	0	1	16

(b) Zbior testowy

Tabela 9: Macierze pomylek dla metody drzew klasyfikacyjnych — wybrane cechy.

Błędy klasyfikacji to 0.059322 i 0.0666667.

```
Cars93.tree.complex  <- rpart(Type ~ ., data=train.subset,
                              control=rpart.control(cp=.01, minsplit=1, maxdepth=30))
plotcp(Cars93.tree.complex)
```

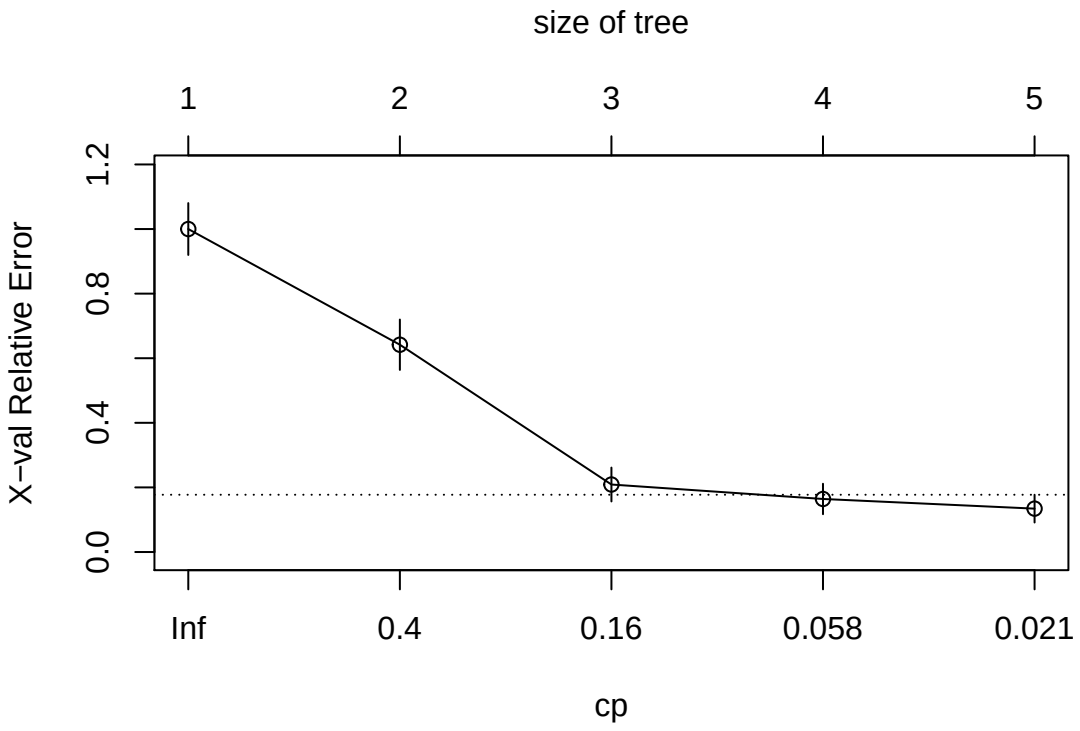


```
printcp(Cars93.tree.complex)
```

```
##
## Classification tree:
## rpart(formula = Type ~ ., data = train.subset, control = rpart.control(cp = 0.01,
##     minsplit = 1, maxdepth = 30))
##
## Variables actually used in tree construction:
## [1] Alcohol    Flavanoids
##
## Root node error: 67/118 = 0.5678
##
## n= 118
##
##         CP nsplit rel error  xerror     xstd
## 1 0.447761      0  1.000000 1.00000 0.080317
## 2 0.358209      1  0.552239 0.64179 0.078028
## 3 0.074627      2  0.194030 0.20896 0.052428
## 4 0.044776      3  0.119403 0.16418 0.047138
## 5 0.010000      4  0.074627 0.13433 0.043035
```

```
bestcp <- Cars93.tree.complex$cptable[which.min(Cars93.tree.complex$cptable[,"xerror"]),
bestcp
```

```
## [1] 0.01
```

```
tuned.tree.model <- train(Type ~ ., data = train.subset, method = "rpart",
                          trControl = cv, tuneLength = 10)

tuned.tree.test.pred <- predict(tuned.tree.model, test.data)
tuned.tree.train.pred <- predict(tuned.tree.model, train.data)
```

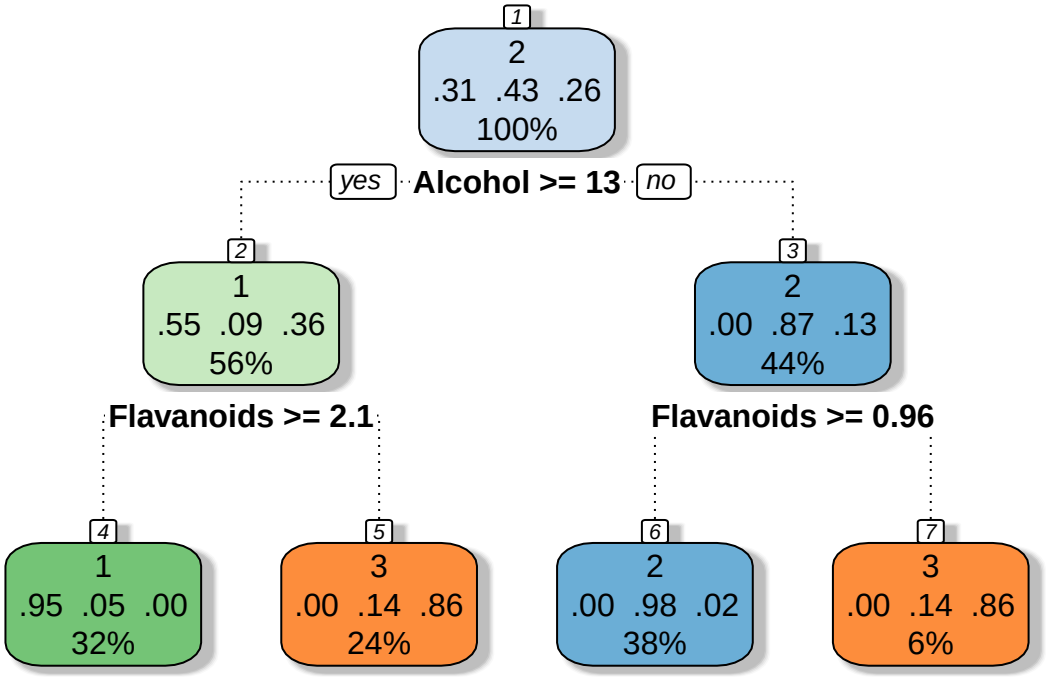

	1	2	3
1	36	2	0
2	0	44	1
3	0	5	30

(a) Zbior uczacy

	1	2	3
1	23	2	0
2	0	16	0
3	0	2	17

(b) Zbior testowy

Tabela 10: Macierze pomylek dla metody drzew klasyfikacyjnych — stuningowany model.

Błędy klasyfikacji to 0.0677966 i 0.0666667.

3.4 Naiwny klasyfikator bayesowski

```
bayes.model.basic <- naiveBayes(Type ~ ., data = train.data)

basic.bayes.train.pred <- predict(bayes.model.basic, train.data)
basic.bayes.test.pred <- predict(bayes.model.basic, test.data)
```

	1	2	3
1	36	0	0
2	0	50	1
3	0	0	31

(a) Zbior uczacy

	1	2	3
1	22	1	0
2	0	19	1
3	0	0	17

(b) Zbior testowy

Tabela 11: Macierze pomylek dla klasyfikatora bayesowskiego — wszystkie cechy.

Błędy klasyfikacji to kolejno 0.0084746 i 0.0333333.

Powtórzmy teraz powyższe dla wybranego podzbioru naszych danych.

```
bayes.model.subset <- naiveBayes(Type ~ ., data = train.subset)

basic.bayes.train.pred <- predict(bayes.model.subset, train.subset)
basic.bayes.test.pred <- predict(bayes.model.subset, test.subset)
```

	1	2	3
1	34	2	0
2	2	47	2
3	0	1	30

(a) Zbior uczacy

	1	2	3
1	20	3	0
2	2	17	1
3	0	0	17

(b) Zbior testowy

Tabela 12: Macierze pomylek dla klasyfikatora bayesowskiego — wybrane cechy.

Błędy klasyfikacji to kolejno 0.059322 i 0.1.

Model “stunigowany”

```
model <- train(Type ~ ., data = train.data, method = "naive_bayes",
               trControl = cv)
```

	1	2	3
1	36	0	0
2	0	50	1
3	0	0	31

(a) Zbior uczacy

	1	2	3
1	22	1	0
2	0	19	1
3	0	0	17

(b) Zbior testowy

Tabela 13: Macierze pomylek dla klasyfikatora bayesowskiego — model stuningowany.

Błędy klasyfikacji w tym przypadku to kolejno 0.0084746 i 0.0333333.

Powtórzymy teraz ocenę klasyfikacji przy pomocy metody 5-krotnej walidacji krzyżowej dla stuningowanego klasyfikatora bayesowskiego, który najlepiej poradził sobie na danym zbiorze treningowym i testowym.

```r
predictor  <- function(model, newdata)
{ predict(model, newdata=newdata) }

naiveBayes.predictor <- function(formula, data)
{ train(formula, data = data, method = "naive_bayes", trControl = cv)}

error.cv <- errorest(Type~., wine, model=naiveBayes.predictor, predict=predictor,
            estimator="cv", est.para=control.errorest(k = 5))

error.cv
```

```
##
## Call:
## errorest.data.frame(formula = Type ~ ., data = wine, model = naiveBayes.predictor,
##     predict = predictor, estimator = "cv", est.para = control.errorest(k = 5))
##
##   5-fold cross-validation estimator of misclassification error
##
## Misclassification error:  0.0337
```